

# Prediction of frost location using machine learning and wireless sensor networks: exploring sensor relationships

Ana Laura Diedrichs and Facundo Bromberg

Laboratorio DHARMA, Dpto Sistemas,  
Facultad Regional Mendoza, Universidad Tecnológica Nacional,  
Rodríguez 273, Ciudad de Mendoza, Argentina, 5500  
{ana.diedrichs,facundo.bromberg}@frm.utn.edu.ar  
<http://dharma.frm.utn.edu.ar>

**Abstract.** Quien escribe en primera persona, Ana Diedrichs, en este documento desplegará información importante sobre la investigación que lleva en curso. Este apunte es una recolección de notas de investigación. Con el objetivo a largo plazo de mejorar la predicción de heladas y realizar una contribución, este documento trata el análisis de las relaciones de variables climáticas, como la temperatura, a microescala, de sensores ubicados en posición vertical. Para ello se analiza las relaciones entre los sensores usando el enfoque de independencia probabilística. Si no existe independencia condicional entre 2 variables dada una tercera, estas dos variables estaría fuertemente correlacionadas entre sí. Basándonos en esta intuición, realizaremos una serie de experimentos y análisis.

## 1 Introducción a la problemática de las heladas

The damage caused by the frost takes place when the temperatures are below than a tolerable limit for the plants. Each phenological state, e.g flowering, has a variable cold hardiness[13], so the lethal temperature is also variable. Freezing climatic events are the most dangerous, because they affect a large land surface. Mendoza is not an exception. According to the Instituto Nacional de Vitivinicultura (INV), in 2013 the loss of the vine crop reached up to 27%[2]. Big part of that loss of yield was during the early spring. In order to study the microclimate phenomenon of frost in Mendoza, sensors should be distributed in the vineyards vertically as well horizontally, because the air temperatures change in both directions, and the plant has also different cold hardiness in the organs like trunk, flowers, shoots.

Previous works on frost prediction have worked with data taken from meteorological stations very distant between them [6][4] [7] or using wireless sensor networks (WSN) [10]. All of them have used supervised machine learning algorithms, such as artificial neural networks and support vector machines, with an particular configuration. For a better understanding of the phenomenon, we propose a study the sensor relationships in order to improve the frost prediction.

30 We are exploring the variables relationships using the independence approach  
31 by learning Markov Network structures [5] from the environmental data corroborating with the opinion of an expert. The analysis of the Markov blanket of  
32 particular sensors helps to identify which neighbor sensors could improve the  
33 prediction.  
34


## 35 2 Hipótesis del Trabajo

36 Existe la posibilidad de desarrollar mecanismos más efectivos respecto al estado  
37 del arte actual para la predicción localizada de heladas en los cultivos, innovando  
38 en la técnica predictiva mediante un estudio de la distribución espacio-temporal  
39 de las variables involucradas y el análisis de sus relaciones *colaborativas entre*  
40 *sensores vecinos* para: anticipar la predicción de la helada y *localizar la zona*  
41 *de ocurrencia* haciendo uso de tecnología de sensado inalámbrica y aprendizaje  
42 automático (machine learning).

## 43 3 Problemática de las Heladas

44 Las heladas constituyen uno de los accidentes de tiempo que causan grandes  
45 pérdidas económicas, a la agricultura en la Argentina y gran parte del mundo,  
46 e impacto social al verse afectado los cultivos de los productores, debido a que  
47 no son fenómenos locales sino extensivos. Existen varias definiciones de helada  
48 como considerar helada a las temperaturas mínimas menores a 0°C. La más  
49 apropiada desde el punto de vista agronómico es *considerar a la helada como*  
50 *el evento meteorológico que ocurre cuando los cultivos y otras plantas experi-*  
51 *mentan daño por congelación*. El daño causado por heladas ocurre cuando las  
52 temperaturas están debajo de un límite tolerable para los cultivos. El umbral de  
53 resistencia de las plantas al frío varía de acuerdo al estado fenológico en el que se  
54 encuentren (floración, frutos o yemas presentes, etc) Según el Instituto Nacional  
55 de Vitivinicultura (INV) en el 2013 la pérdida de viñedo por helada llegó a un  
56 27% [2]. Las heladas tardías en Mendoza suceden entre septiembre y noviembre  
57 siendo muy peligrosas porque empieza la floración y ya hay yemas brotadas.



58 Existen dos tipos de heladas. Las heladas advectivas se caracterizan por los al-  
59 tos niveles de humedad, escarcha y cielo nublados. Las heladas radiativas suceden  
60 bajo cielo despejado, escaso viento y muy baja humedad. Estas últimas son con-  
61 sideradas muy peligrosas porque el balance calórico disminuye drásticamente en  
62 la noche despejada al perderse el calor recibido durante el día. Para la medición  
63 de variables ambientales comúnmente se utilizan estaciones meteorológicas. Ac-  
64 tualmente las mismas están instaladas muy distanciadas unas de las otras, por  
65 lo que no son suficientes para caracterizar un fenómeno micro-climático. A esto  
66 se suma que la casilla meteorológica está a una altura promedio entre los 1.5m y  
67 2m, como lo ilustra la figura[9] anterior; impidiendo caracterizar el fenómeno de  
68 la inversión térmica. En el siguiente gráfico [8] se muestran las temperaturas du-  
69 rante una noche de heladas de seis sensores posicionados verticalmente (a nivel  
70 del suelo, 40cm, 75 cm, 1.5m, 2 m, 3 m) donde podemos visualizar la variabilidad



71 de la amplitud térmica a distintas alturas. Esto sucede porque el aire frío es más  
 72 denso y fluye hacia las capas más bajas, en consecuencia drena hacia la parte  
 73 más baja del terreno; mientras que el aire más caliente queda estratificado en  
 74 la altura. Por esto es importante medir la variable de interés (temperatura) in  
 75 situ y a distintas alturas. La predicción de heladas es importante porque permite  
 76 activar con tiempo los mecanismos de prevención activa. Durante las noches de  
 77 heladas suelen utilizarse quemadores, molinos de viento, aspersores, entre otras  
 78 técnicas que permiten generar o mejorar la circulación del calor donde se encuen-  
 79 tran los cultivos. Por otra parte, la predicción localizada de heladas permitiría  
 80 saber no sólo si helará o no ese día, sino también las zonas de una finca o región  
 81 que se verían afectadas.

## 82 4 Hyphotesis

83 Hyphotesis: It is possible to improve the temperature sensor prediction taking  
 84 advantage of the sensor neighbors information. Given the temperature predic-  
 85 tion of a place  $S_i$ , we are asking if it could improve with the information given  
 86 by a sensor neighbor  $S_j$ .



87

## 88 5 Markov networks approach

89 In order to analyze how related is a sensor respect others, we are going to use the  
 90 probabilistic independence approach. A common way of probability distribution  
 91 representations is conditional independence. Two events  $\alpha$  and  $\beta$  are independent

iff  $P(\alpha|\beta) = P(\alpha)$ . It means if you know that  $\beta$  occurs, it does not change the probability of occurrence of  $\alpha$ . Markov networks are undirected graphical models which represent a joint probability distribution over the variables. Each node of the graph is a random variable of the domain and each edge between nodes represents a dependency conditional relationship between both variables. Given a Markov network it is able to find the conditional independence over the variables respect others. It is possible to learn Markov network from data using structure learning algorithms. We have chosen independence structure learning approach [12] for knowledge discovering.

## 6 Mutual Information approach

Entropy measures the amount of information (or uncertainty) of a random variable. Given  $X$ , a discreted random variable and  $P(x)$  its probability distribution, the entropy  $H(X)$  is calculated as (1)

$$H(X) = \sum_{x \in X} P(x) \log P(x) \quad (1)$$

If the log base 2 is used, the units are the bit. By definition  $H(X) \geq 0$ . The joint entropy represents the amount of information needed on average to specify the value of two discrete random variables  $X$  and  $Y$  which is given by (2)

$$H(X, Y) = \sum_{x \in X} \sum_{y \in Y} P(x, y) \log P(x, y) \quad (2)$$

The conditional entropy indicates how much extra information you still need to supply on average to communicate  $Y$  given that the other party knows  $X$ . Conditional entropy  $H(X|Y)$  measures the amount of uncertainty in  $X$  after we know the value of  $Y$  (on average):  $H(Y|X) = H(X, Y) - H(X)$

$$H(Y|X) = \sum_{x \in X} \sum_{y \in Y} P(x, y) \log P(y|x) \quad (3)$$

Mutual information measures the information that  $X$  and  $Y$  share: it measures how much knowing one of these variables reduces uncertainty about the other.

$$I(X, Y) = \sum_{x \in X} \sum_{y \in Y} P(x, y) \frac{\log P(x, y)}{P(x)P(y)} \quad (4)$$

where  $p(x, y)$  is the joint probability distribution function of  $X$  and  $Y$ , and  $p(x)$  and  $p(y)$  are the marginal probability distribution functions of  $X$  and  $Y$  respectively. It is the marginal additional information someone, analyzing  $X$ , gains from knowing  $Y$ . Moreover,  $I(X, Y)$  is symmetric and non-negative.  $I(X, Y) = I(Y, X)$ . If  $I(X, Y) = 0$ , then  $X$  and  $Y$  are independent.

We analyze the conditional entropy of the sensor and their relationships in a present time  $t$  and a future time  $T$  in order to answer:

- 122 1) How much reduces the entropy of  $H(S_{iT}|S_{it})$  which indicates how much  
 123 information gives  $S_{iT}$  given that we have  $S_{it}$   
 124 2) How much information gives a neighbor  $S_{jt}$ , calculating  $H(S_{iT}|S_{it}, S_{jt})$

## 125 7 Experimental setup

126 Se procedera a explicar las características del origen de los datos en 7.1 y su  
 127 posterior procesamiento en 7.2 (discretización, consideración temporal) para dar  
 128 origen a otros datasets, que sirvan como entrada para el aprendizaje de estruc-  
 129 tura de markov y para el análisis de mutual info. En 7.2 se presenta la config-  
 130 uración utilizada para el aprendizaje de estructuras. Por último se desglosa los  
 131 resultados de mutual info.

### 132 7.1 Data source

133 Six temperature sensor[1] from a research project [8] where placed at different  
 134 heights, as we can see on table 7.1. The sampling interval was set to a minute.  
 135 They represent six temperature variables located in the same  $(x, y)$  position var-  
 136 ing their height. The data was acquired between 07/21/2012 and 07/26/2012,  
 137 a week with frost events. For each sensor there are 7330 datapoints.

Temperature sensor	Sensor at time t	Sensor at t + T
ground level	$S_1$	$S_7$
40 cm height	$S_2$	$S_8$
75cm height	$S_3$	$S_9$
1.5m height	$S_4$	$S_{10}$
2m height	$S_5$	$S_{11}$
3m height	$S_6$	$S_{12}$

**Table 1.** Variables of interest

### 138 7.2 Pre-processing

139 The continuous temperature data is ranging from a minimum  $-9.8^{\circ}\text{C}$  to  $26.8^{\circ}\text{C}$ .  
 140 It was discretized with eight intervals with the same width.

141 For the temporal discretization, three options of time displacement inter-  
 142 val were chosen: 6, 8 and 12 hours; which were labeled with T-1, T-2 y T-3  
 143 respectively.

144 **Dataset design** Para tomar en cuenta el valor de la variable  $S_i$  en un tiempo  
 145  $T$  posterior, se diseñó dos tipos de datasets que pasará a explicar.

ESTE NO VA A L POSTER Para analizar la relación de todas las variables  $S_{it}$  en  $t = t_0$ , versus la predicción de alguna de ellas  $S_{kT}$ ,  $i \neq k$ , en un  $t = T$ , donde  $i = 1..N$  y  $N$  el número total de sensores. Se construyó un dataset cuyas columnas concatenan las variables de la siguiente manera: Una columna para cada  $S_{it}$  (total  $N$  columnas) y una columna  $S_{kT}$ .

– For analyzing the relationship between the variables  $S_{it}$  in  $t = t_0$ , where  $i = 1..N$  and  $N$  is the total number of sensors, versus the prediction of  $S_{iT}$  in  $t = T$ , a dataset was built whose columns concatenate the variables as follow: one column per each  $S_{it}$  and then one column per each  $S_{iT}$ .

El número total de datasets resultantes está definido por  $(N + 1) * T$ . Dado que tomaremos 3 períodos futuros,  $T \in (6,8,12)$ , y  $N = 6$  para nuestro caso, contamos con 21 datasets generados.

**Aprendizaje de estructuras: setup** The setup of structured learning is listed below on Table 7.2. The first column is the algorithm used ("SL algorithm"), the second the test used to calculated if two variables are independent, and the third is the threshold used for the test.

Agregar una intro a cada uno de ellos

**Table 2.** Setup para aprendizaje de estructuras

SL algorithm	Test	Threshold
HHC-MN [11]	$G^2$	0.001, 0.01, 0.05
GSMN [3]	$G^2$	0.001, 0.01, 0.05
PC [14]	$G^2$	0.001, 0.01, 0.05
IBMAP-HC [11]	bayesian test	0.5

### 7.3 Resultados Markov networks

Las estructuras resultantes para los algoritmos pc, gsmn, hhc se encuentran en scripts/structured-learning/output/structures, y para ibmaph en scripts/structured-learning/output-ibmaph/structures. Los archivos que guardan las estructuras son extensiones .ugraph. La nomenclatura a utilizar es la indicada en la Tabla 7.1

The Figure 7.3 shows the result of apply OR-operand (counting all edges) between all the Adjacency matrix obtained from the structured learning algorithms with the following setup: threshold 0.001, except IBMAPH with 0.5, and  $T = 3$  (12 hs). The columns and rows show the variable number, for example 1 is  $S_1$ , which are listed on Table 7.1. We can see that still with a big confidence interval remains dependencies between the variables. The relationships between

one sensor with its next-door neighbor, which is located over or below itself, reflects the typical thermodynamic behavior because one layer of air is related with other. Edges between  $S_1$  and  $S_5$  explain where the inversion layer is located. The inversion layer is the division between the cool air and heat air.

	1	2	3	4	5	6	7	8	9	10	11	12
1	0	2	1	1	4	1	1	2	0	1	0	1
2	2	0	4	1	1	2	1	0	0	0	0	2
3	1	4	0	4	1	1	1	0	1	0	0	0
4	1	1	4	0	4	1	0	0	0	1	0	1
5	4	1	1	4	0	4	0	0	0	0	0	1
6	1	2	1	1	4	0	2	1	2	0	1	2
7	1	1	1	0	0	2	0	3	1	0	3	2
8	2	0	0	0	0	1	3	0	3	2	0	2
9	0	0	1	0	0	2	1	3	0	3	0	1
10	1	0	0	1	0	0	0	2	3	0	3	1
11	0	0	0	0	0	1	3	0	0	3	0	3
12	1	2	0	1	1	2	2	2	1	1	3	0

Fig. 1. —

En el siguiente enlace de gdrive contiene las tablas como la de arriba [https://docs.google.com/spreadsheets/d/16cIB4ZQ2kGtz6V0BqyA9paCYtCYshQuPt7\\_hV0eqDxs/edit?usp=sharing](https://docs.google.com/spreadsheets/d/16cIB4ZQ2kGtz6V0BqyA9paCYtCYshQuPt7_hV0eqDxs/edit?usp=sharing)

## 8 Resultados mutual information

Los cálculos de mutual information se encuentran implementados en el archivo mutual.information.R, método run.experiment.cond.entropy. Se procedió a calcular los siguiente:

1) La entropía de  $S_{iT}$  dado  $S_{it}$  se refleja como  $H(S_{iT}|S_{it})$ , que significa cuanta información extra requiere  $S_{iT}$  dado que tiene/sabe  $S_{it}$ . ¿En cuánto me ayuda a disminuir la incertidumbre de  $S_{iT}$  saber  $S_{it}$ ?

2) Por otra parte, nos interesa saber cuanta información me otorga agregar a un vecino  $S_{jt}$ , y se refleja en la entropía  $H(S_{iT}|S_{it}, S_{jt})$

Los cálculos son en base e, en consecuencia el resultado son nats (no bits).

En la vector de resultados de  $H(S_{iT}|S_{it})$  cada posición  $i$  guarda el valor de uno de los cálculos. En la matriz de resultados de  $H(S_{iT}|S_{it}, S_{jt})$ , un resultado



194 en la posición (i,j) siendo i la fila y j la columna; por ej, la fila de s\_2 y columna  
 195 s3\_t guarda el resultado de calcular  $H(S_{2T}|S_{2t}, S_{3t})$ .

196 Each cell (i,j), where  $i$  is the row and  $j$  the column, of the matrix stores one  
 197 result of  $H(S_{iT}|S_{it}, S_{jt})$ . For example the row 2 ( $S_2$ ) and column  $S_3$  stores the  
 198 result of calculate  $H(S_{2T}|S_{2t}, S_{3t})$ .

```

199 > run.experiment.cond.entropy()
200 [1] "/home/usuario/phd/heladas/frost/heladas/scripts/datasets/T_1_b_8.csv"
201 CALCULO DE H(X)  X=S_T
202     value
203 s1  8.69
204 s2  8.74
205 s3  8.76
206 s4  8.77
207 s5  8.77
208 s6  8.78
209 CALCULO DE H(X | Y) donde:  X=S_T      Y=S_t
210     value
211 s1  1.65
212 s2  1.56
213 s3  1.52
214 s4  1.50
215 s5  1.49
216 s6  1.48
217 CALCULO DE H(X | Y,Z) donde:  X=Si_T      Y=Si_t      Z=Sj_t
218     s1  s2  s3  s4  s5  s6
219 s1 1.65 1.50 1.45 1.49 1.46 1.48
220 s2 1.41 1.56 1.50 1.48 1.43 1.49
221 s3 1.34 1.47 1.52 1.47 1.43 1.46
222 s4 1.33 1.43 1.45 1.50 1.43 1.43
223 s5 1.32 1.39 1.42 1.44 1.49 1.40
224 s6 1.32 1.42 1.42 1.41 1.38 1.48
225 MUTUAL INFO I(X,Z|Y) donde:  X=Si_T      Y=Si_t      Z=Sj_t
226     s1  s2  s3  s4  s5  s6
227 s1 0.00 0.15 0.19 0.16 0.18 0.17
228 s2 0.16 0.00 0.06 0.08 0.14 0.07
229 s3 0.18 0.05 0.00 0.05 0.09 0.05
230 s4 0.17 0.07 0.05 0.00 0.07 0.07
231 s5 0.17 0.11 0.07 0.05 0.00 0.09
232 s6 0.16 0.06 0.06 0.07 0.10 0.00
233 METRICA razon o division del 3ro con el 2do
234     s1  s2  s3  s4  s5  s6
235 s1 1.00 0.91 0.88 0.90 0.89 0.90
236 s2 0.90 1.00 0.96 0.95 0.91 0.95
237 s3 0.88 0.97 1.00 0.97 0.94 0.96
238 s4 0.88 0.95 0.97 1.00 0.95 0.95

```

```

239 s5 0.88 0.93 0.95 0.96 1.00 0.94
240 s6 0.89 0.96 0.96 0.96 0.93 1.00
241 porcentaje de reducción de la entropía
242     s1  s2  s3  s4  s5  s6
243 s1 0.00 0.09 0.12 0.10 0.11 0.10
244 s2 0.10 0.00 0.04 0.05 0.09 0.05
245 s3 0.12 0.03 0.00 0.03 0.06 0.04
246 s4 0.12 0.05 0.03 0.00 0.05 0.05
247 s5 0.12 0.07 0.05 0.04 0.00 0.06
248 s6 0.11 0.04 0.04 0.04 0.07 0.00
249 [1] "/home/usuario/phd/heladas/frost/heladas/scripts/datasets/T_2_b_8.csv"
250 CALCULO DE H(X) X=S_T
251     value
252 s1  8.67
253 s2  8.72
254 s3  8.74
255 s4  8.75
256 s5  8.75
257 s6  8.76
258 CALCULO DE H(X | Y) donde: X=S_T Y=S_t
259     value
260 s1  1.58
261 s2  1.45
262 s3  1.43
263 s4  1.35
264 s5  1.40
265 s6  1.36
266 CALCULO DE H(X | Y,Z) donde: X=Si_T Y=Si_t Z=Sj_t
267     s1  s2  s3  s4  s5  s6
268 s1 1.58 1.41 1.38 1.40 1.39 1.39
269 s2 1.36 1.45 1.39 1.38 1.37 1.39
270 s3 1.30 1.37 1.43 1.34 1.34 1.34
271 s4 1.25 1.29 1.29 1.35 1.30 1.29
272 s5 1.26 1.29 1.30 1.33 1.40 1.33
273 s6 1.23 1.29 1.28 1.29 1.29 1.36
274 MUTUAL INFO I(X,Z|Y) donde: X=Si_T Y=Si_t Z=Sj_t
275     s1  s2  s3  s4  s5  s6
276 s1 0.00 0.17 0.20 0.18 0.19 0.19
277 s2 0.09 0.00 0.06 0.08 0.08 0.06
278 s3 0.12 0.06 0.00 0.08 0.09 0.08
279 s4 0.10 0.06 0.06 0.00 0.05 0.07
280 s5 0.14 0.11 0.10 0.07 0.00 0.07
281 s6 0.13 0.07 0.07 0.06 0.07 0.00
282 METRICA razon o division del 3ro con el 2do
283     s1  s2  s3  s4  s5  s6

```

```

284 s1 1.00 0.89 0.87 0.89 0.88 0.88
285 s2 0.94 1.00 0.96 0.95 0.94 0.96
286 s3 0.91 0.96 1.00 0.94 0.94 0.94
287 s4 0.92 0.95 0.96 1.00 0.96 0.95
288 s5 0.90 0.92 0.93 0.95 1.00 0.95
289 s6 0.91 0.95 0.95 0.95 0.95 1.00
290 porcentaje de reducción de la entropía
291     s1    s2    s3    s4    s5    s6
292 s1 0.00 0.11 0.13 0.11 0.12 0.12
293 s2 0.06 0.00 0.04 0.05 0.06 0.04
294 s3 0.09 0.04 0.00 0.06 0.06 0.06
295 s4 0.08 0.05 0.04 0.00 0.04 0.05
296 s5 0.10 0.08 0.07 0.05 0.00 0.05
297 s6 0.09 0.05 0.05 0.05 0.05 0.00
298 [1] "/home/usuario/phd/heladas/frost/heladas/scripts/datasets/T_3_b_8.csv"
299 CALCULO DE H(X)  X=S_T
300     value
301 s1  8.63
302 s2  8.69
303 s3  8.70
304 s4  8.71
305 s5  8.72
306 s6  8.73
307 CALCULO DE H(X | Y) donde:  X=S_T      Y=S_t
308     value
309 s1  1.40
310 s2  1.37
311 s3  1.31
312 s4  1.33
313 s5  1.32
314 s6  1.24
315 CALCULO DE H(X | Y,Z) donde:  X=Si_T      Y=Si_t      Z=Sj_t
316     s1    s2    s3    s4    s5    s6
317 s1 1.40 1.31 1.29 1.29 1.29 1.29
318 s2 1.28 1.37 1.33 1.32 1.31 1.31
319 s3 1.19 1.27 1.31 1.28 1.25 1.24
320 s4 1.21 1.26 1.27 1.33 1.28 1.26
321 s5 1.22 1.25 1.26 1.28 1.32 1.26
322 s6 1.15 1.19 1.17 1.18 1.19 1.24
323 MUTUAL INFO I(X,Z|Y) donde:  X=Si_T      Y=Si_t      Z=Sj_t
324     s1    s2    s3    s4    s5    s6
325 s1 0.00 0.09 0.11 0.11 0.12 0.12
326 s2 0.09 0.00 0.04 0.06 0.06 0.06
327 s3 0.12 0.04 0.00 0.03 0.06 0.07
328 s4 0.11 0.07 0.05 0.00 0.05 0.07

```

```

329 s5 0.09 0.07 0.06 0.04 0.00 0.05
330 s6 0.09 0.05 0.07 0.06 0.05 0.00
331 METRICA razon o division del 3ro con el 2do
332      s1  s2  s3  s4  s5  s6
333 s1 1.00 0.93 0.92 0.92 0.92 0.92
334 s2 0.94 1.00 0.97 0.96 0.96 0.96
335 s3 0.91 0.97 1.00 0.98 0.95 0.95
336 s4 0.91 0.95 0.96 1.00 0.96 0.95
337 s5 0.93 0.95 0.96 0.97 1.00 0.96
338 s6 0.92 0.96 0.94 0.95 0.96 1.00
339 porcentaje de reducci3n de la entropía
340      s1  s2  s3  s4  s5  s6
341 s1 0.00 0.07 0.08 0.08 0.08 0.08
342 s2 0.06 0.00 0.03 0.04 0.04 0.04
343 s3 0.09 0.03 0.00 0.02 0.05 0.05
344 s4 0.09 0.05 0.04 0.00 0.04 0.05
345 s5 0.07 0.05 0.04 0.03 0.00 0.04
346 s6 0.08 0.04 0.06 0.05 0.04 0.00

```

## 347 9 Open issues

- 348 – Complete interpretation with an expert of the markov networks: could they
- 349 help to understand the frost phenomenon?
- 350 – Setup of the prediction model: input and output variables
- 351 – Discretization of continuous features: sensor values and time
- 352 – How to infer the best sensor location in order to optimize the prediction and
- 353 the number of sensor needed.

## 354 References

- 355 1. Logtag: humidity and temperature recorder. datasheet. On-
- 356 line. [http://logtagrecorders.com/products/pdf/LogTag\\_HAXO-](http://logtagrecorders.com/products/pdf/LogTag_HAXO-8_Product_Specification.pdf)
- 357 [8\\_Product\\_Specification.pdf](http://logtagrecorders.com/products/pdf/LogTag_HAXO-8_Product_Specification.pdf).
- 358 2. El INV presentó el ajuste de la Estimación de Cosecha 2014. online news, Instituto
- 359 Nacional de la Vitivinicultura, Mendoza, Argentina, February 2014.
- 360 3. Facundo Bromberg, Dimitris Margaritis, Vasant Honavar, et al. Efficient markov
- 361 network structure discovery using independence tests. *Journal of Artificial Intel-*
- 362 *ligence Research*, 35(2):449, 2009.
- 363 4. Luca Ghielmi and Emanuele Eccel. Descriptive models and artificial neural net-
- 364 works for spring frost prediction in an agricultural mountain area. *Computers and*
- 365 *electronics in agriculture*, 54(2):101–114, 2006.
- 366 5. Daphne Koller and Nir Friedman. *Probabilistic graphical models: principles and*
- 367 *techniques*. MIT press, 2009.
- 368 6. Brenda B Lin. Agroforestry management as an adaptive strategy against potential
- 369 microclimate extremes in coffee agriculture. *Agricultural and Forest Meteorology*,
- 370 144(1):85–94, 2007.

- 371 7. Imran Maqsood, Muhammad Riaz Khan, and Ajith Abraham. An ensemble of neu-  
372 ral networks for weather forecasting. *Neural Computing & Applications*, 13(2):112–  
373 122, 2004.
- 374 8. Remugnán Daniel (Co-director) Rojas Daniel (Director). Defensa activa contra  
375 heladas. Utilización de energía geotérmica de baja temperatura. Proyecto de in-  
376 vestigación, Facultad de Ciencias Agrarias, Universidad Nacional de Cuyo.
- 377 9. M. Saavedra. Caracterización física de heladas radiativas en el valle del mantaro.  
378 Master’s thesis, Universidad Nacional Mayor de San Marcos, 2013.
- 379 10. P Sallis, M Jarur, M Trujillo, and A Ghobakhloo. Frost prediction using a combina-  
380 tional model of supervised and unsupervised neural networks for crop management  
381 in vineyards. In *18th IMACS World Congress-MODSIM09 International Congress*  
382 *on Modelling and Simulation*, pages 13–17, 2009.
- 383 11. F. Schlüter, F. Bromberg, and A. Edera. The Ibmmap approach for Markov network  
384 structure learning. *Annals of Mathematics and Artificial Intelligence*, pages 1–27,  
385 2014.
- 386 12. Federico Schlüter. A survey on independence-based markov networks learning.  
387 *Artificial Intelligence Review*, pages 1–25, 2012.
- 388 13. Richard L Snyder and J Paulo Melo-Abreu. *Frost protection: fundamentals, prac-*  
389 *tice and economics. Volume 1.* FAO, 2005.
- 390 14. Peter Spirtes, Clark Glymour, and Richard Scheines. Causation, prediction, and  
391 search. adaptive computation and machine learning, 2000.

## 392 Appendix: Otros issues

- 393 1. Se puede optimizar la ubicación de los sensores en una finca para maximizar  
394 el poder de los algoritmos predictivos (Kriging, Conditional Random Fields).
- 395 2. *Discretización*: Existen otros criterios para discretizar como el criterio de  
396 Sturge que computa  $k = \log_2 n + 1$ , donde  $n$  es el número total de datapoints  
397 (instancias de dato, hechos, filas). Hasta la versión (commit)

### NOMBRAR LA VERSION

398 no investigué adecuadamente como discretizar las variables y elegí probar con  
399 distintos números de intervalos k. Un método de discretización interesante  
400 que encontré fue Ameva, whose objective is to maximize the dependence  
401 between the intervals that divide the values of an attribute and the classes  
402 to which they belong, providing at the same time the minimum number of  
403 intervals. En R, la librería discretizacion lo trae implementado. Para usarlo,  
404 llamar al método `disc.Topdown(data,method=3)`. La ventaja de AMEVA es  
405 que uno puede desligarse de indicarle el valor de k o h al algoritmo, lo calcula  
406 solo. mas info: unas slides introductorias pero mencionan todos los aspectos  
407 vinculados a discretización (SLIDES <http://stat.skku.ac.kr/myhuh/homepage/specialLectures/SDULEC>)  
408 Recopilación de info interesante sobre mutual information y su implementación  
409 en R.  
410  
411

412 RECOMENDABLE!!! --> Entropy-Based Inference using R and the np Package:  
413 A Primer [http://socserv.mcmaster.ca/racine/entropy\\_np.pdf](http://socserv.mcmaster.ca/racine/entropy_np.pdf)  
414

415 OTRO DOC más info en "Inequality, Entropy and Goodness of Fit"  
416 <http://personal.lse.ac.uk/BANDYOPS/GoF1.pdf>  
417 UNAS SLIDES ACLARATORIAS [http://www.unc.edu/~maguilar/metrics/MySlides\\_trans2.pdf](http://www.unc.edu/~maguilar/metrics/MySlides_trans2.pdf)